

# Zadanie 4 z listy 6 - “Kompresja Danych”

Łukasz Klasieński

10 maja 2020

## Zadanie 4

Pokaż, że dla słów postaci  $(a_1a_2 \dots a_m)^*$  algorytm Sequitur wykona  $\Omega(n)$  operacji dodania nowej produkcji i  $\Omega(n)$  operacji usunięcia produkcji (gdzie  $n$  to długość słowa).

## Rozwiązanie

1.  $\Omega(n)$  operacji dodania nowej produkcji: Zauważmy, że na początku po wczytaniu pojedynczego  $(a_1a_2 \dots a_m)$ , będziemy mieli pojedynczą produkcję:

$$S \rightarrow a_1a_2 \dots a_m$$

Po wczytaniu kolejnego znaku  $a_1$ , nic się nie stanie. Z kolei po dodaniu symbolu  $a_2$ , dostaniemy powtórzenie:

$$S \rightarrow a_1a_2 \dots a_ma_1a_2$$

Zatem wyrzucimy je i dodamy nową produkcję:

$$S \rightarrow Aa_3 \dots a_mA$$

$$A \rightarrow a_1a_2$$

Następnie po dodaniu  $a_3$  algorytm zauważy powtórzenie  $Aa_3 \dots a_mAa_3$ , zatem stworzy nową produkcję:

$$S \rightarrow Ba_4 \dots a_mB$$

$$A \rightarrow a_1a_2$$

$$B \rightarrow Aa_3$$

Ale teraz mamy kolejne załamanie niezmiennika - produkcja  $A$  występuje tylko raz. Zatem usunie się, i zostaną produkcje

$$S \rightarrow Ba_4 \dots a_mB$$

$$B \rightarrow a_1a_2a_3$$

Dodajemy  $a_4$  - dostajemy produkcję

$$S \rightarrow Ca_5 \dots a_mC$$

$$B \rightarrow a_1a_2a_3$$

$$C \rightarrow Ba_4$$

I znowu  $B$  jest użyte tylko raz, więc zostanie usunięte.

Sytuacja powtarza się aż do dojścia do zakodowania słowa  $a_1 \dots a_ma_1 \dots a_m$ .

Zobaczmy teraz co się stanie gdy mamy już produkcję  $S$  i dodajemy kolejne słowa z cyklu.

Wiemy że poza  $S$  mamy jeszcze produkcję  $G \rightarrow a_1a_2 \dots a_m$ . Zatem widać że po dodaniu do  $S$   $a_1$  nic się nie stanie, ponieważ aby coś zmieniać musimy mieć dopasowanie wielkości 2.

Dodajmy  $a_k$ . Mamy dwa przypadki:

1. Mamy tylko jedną produkcję  $G \rightarrow a_1 a_2 \dots a_m$ . Wtedy możemy zmachować  $a_{k-1} a_k$  z  $G$  i stworzyć nową produkcję. Zatem wykonujemy jedną operację dodania produkcji.
2. Mamy produkcję  $G \rightarrow a_1 \dots K a_k a_{k+1} \dots a_m$  oraz  $K \rightarrow a_i \dots a_{k-1}$ . Wtedy możemy stworzyć nową produkcję  $X \rightarrow K a_k$ , po czym zastąpić w  $K a_k$  w  $G$  na  $X$  i usunąć  $K$ , zamieniając  $X \rightarrow K a_k$  na to co miało  $K$ . Zatem usuwamy i dodajemy po jednej produkcji.
3. Dodajemy ostatnie słowo z cyklu -  $a_m$ . Wtedy  $G \rightarrow K a_m$  oraz  $K \rightarrow a_1 a_2 \dots a_{m-1}$ , zatem po zastąpieniu  $K a_m$  poprzez nową produkcję  $X \rightarrow K a_m$ , będziemy mogli usunąć produkcję  $K$  oraz  $X$  i otrzymamy  $G \rightarrow a_1 a_2 \dots a_m$ , czyli wrócimy do punktu 1). Łącznie dodajemy produkcję, po czym usuwamy dwie.

Widać zatem, że wykonujemy zamortyzowanie dokładnie jedną operację dodania predykatu oraz jedną operację usunięcia podczas dodawania wszystkich znaków z alfabetu poza  $a_1$ . Poza tymi operacjami mamy także dodatkowe operacje dodania predykatu w ramach zawijania produkcji  $S \rightarrow XXXX$  na nowy predykat (jest  $\log n$  takich operacji). Zatem ostatecznie w algorytmie wykonamy  $O(n)$  operacji dodawania i usuwania, więc dla odpowiednio dużego  $n$ ,  $\Omega(n)$  jest prawdziwa.