

# Zadanie 4 z listy 6 - “Kompresja Danych”

Łukasz Klasinski

3 maja 2020

## Zadanie 4

Pokaż, że dla słów postaci  $(a_1a_2 \dots a_m)^*$  algorytm Sequitur wykona  $\Omega(n)$  operacji dodania nowej produkcji i  $\Omega(n)$  operacji usunięcia produkcji (gdzie  $n$  to długość słowa).

## Rozwiązanie

1.  $\Omega(n)$  operacji dodania nowej produkcji: Zauważmy, że na początku po wczytaniu pojedynczego  $(a_1a_2 \dots a_m)$ , będziemy mieli pojedynczą produkcję:

$$S \rightarrow a_1a_2 \dots a_m$$

Po wczytaniu kolejnego znaku  $a_1$ , nic się nie stanie. Z kolei po dodaniu symbolu  $a_2$ , dostaniemy powtórzenie:

$$S \rightarrow a_1a_2 \dots a_ma_1a_2$$

Zatem wyrzucimy je i dodamy nową produkcję:

$$S \rightarrow Aa_3 \dots a_mA$$

$$A \rightarrow a_1a_2$$

Następnie po dodaniu  $a_3$  algorytm zauważy powtórzenie  $Aa_3 \dots a_mAa_3$ , zatem stworzy nową produkcję:

$$S \rightarrow Ba_4 \dots a_mB$$

$$A \rightarrow a_1a_2$$

$$B \rightarrow Aa_3$$

Ale teraz mamy kolejne załamanie niezmiennika - produkcja  $A$  występuje tylko raz. Zatem usunie się, i zostaną produkcje

$$S \rightarrow Ba_4 \dots a_mB$$

$$B \rightarrow a_1a_2a_3$$

Dodajemy  $a_4$  - dostajemy produkcję

$$S \rightarrow Ca_5 \dots a_mC$$

$$B \rightarrow a_1a_2a_3$$

$$C \rightarrow Ba_4$$

I znowu  $B$  jest użyte tylko raz, więc zostanie usunięte.

Sytuacja powtarza się aż do dojścia do zakodowania słowa  $a_1 \dots a_ma_1 \dots a_m$ .

Zobaczmy teraz co się stanie gdy mamy już produkcję  $S$  i dodajemy kolejne słowa z cyklu.

Wiemy że poza  $S$  mamy jeszcze produkcję  $G \rightarrow a_1a_2 \dots a_m$ . Zatem widać że po dodaniu do  $S$   $a_1$  nic się nie stanie, ponieważ aby coś zmieniać musimy mieć dopasowanie wielkości 2.

Dodajmy  $a_k$ . Mamy dwa przypadki:

1. Mamy tylko jedną produkcję  $G \rightarrow a_1 a_2 \dots a_m$ . Wtedy możemy zmachować  $a_{k-1} a_k$  z  $G$  i stworzyć nową produkcję. Zatem wykonujemy jedną operację dodania produkcji.
2. Mamy produkcję  $G \rightarrow a_1 \dots K a_k a_{k+1} \dots a_m$  oraz  $K \rightarrow a_i \dots a_{k-1}$ . Wtedy możemy stworzyć nową produkcję  $X \rightarrow K a_k$ , po czym zastąpić w  $K a_k$  w  $G$  na  $X$  i usunąć  $K$ , zamieniając  $X \rightarrow K a_k$  na to co miało  $K$ . Zatem usuwamy i dodajemy po jednej produkcji.
3. Dodajemy ostatnie słowo z cyklu -  $a_m$ . Wtedy  $G \rightarrow K a_m$  oraz  $K \rightarrow a_1 a_2 \dots a_{m-1}$ , zatem po zastąpieniu  $K a_m$  poprzez nową produkcję  $X \rightarrow K a_m$ , będziemy mogli usunąć produkcję  $K$  oraz  $X$  i otrzymamy  $G \rightarrow a_1 a_2 \dots a_m$ , czyli wrócimy do punktu 1). Łącznie dodajemy produkcję, po czym usuwamy dwie.

Widać zatem, że wykonujemy zamortyzowanie dokładnie jedną operację dodania predykatu oraz jedną operację usunięcia dla podczas dodawania wszystkich znaków z alfabetu poza  $a_1$ . Poza tymi operacjami mamy także dodatkowe operacje dodania predykatu w ramach zawijania produkcji  $S \rightarrow XXXX$  na nowy predykat (jest  $\log n$  takich operacji). Zatem ostatecznie w algorytmie wykonamy  $O(n)$  operacji dodawania i usuwania, więc dla odpowiednio dużego  $n$ ,  $\Omega(n)$  jest prawdziwa.